

工具包落地盘点报告

RFPerm / OnlineRFPerm / PO-learner / FSDS / 多层特征图算法
在大模型推理预测、对齐与数据质量一致性中的可直接落地场景

内部方法盘点（基于开源 PDF、仓库实现与本地已就绪数据）

日期：2026-09-15

摘要

本报告对一组**已开源、已实现、数据已就绪**的分布漂移诊断与适应工具做总体盘点，并回答一个产品问题：在大模型（LLM）**推理/预测、对齐、幻觉监控、合成数据质量与表征一致性**场景里，哪些可以直接落地、怎么落地、不要过宣称什么。

工具包覆盖五层能力：(i) **RFPerm**——模型无关的预测退化置换检验；(ii) **OnlineRFPerm**——流式监测 + Online FDR；(iii) **PO-learner / CFPerm / DRPerm / RRPerm**——把新旧批次当作 $T \in \{0, 1\}$ ，用因果目标函数做分布距离与 OOD 变量重要性；(iv) **FSDS**——协变量漂移 $P(X)$ 与概念漂移 $P(Y | X)$ 的特征选择基准与生产诊断；(v) **多层 / 多场景 / 特征库图算法**——对 user-item-session、模态塔、特征家族做 ASSOC/HSIC 链路 & 分层子集定位。

核心立场（不打折）：这些方法回答的是**检测、定位、重加权/门控、调度算力**；它们**不是事实核查器**，也不在无额外结构时唯一分解「协变量 vs 概念」到单特征因果。KL 可加分解不自动迁移到任意距离；全空间唯一归因是不可能的，**子集定位**才是生产正确动作。

直接可落地的优先场景（数据已就绪）：

1. 流式幻觉/错误率**制度跳变**监测（OnlineRFPerm + po_risk0 排序）；
2. 合成数据 / 蒸馏数据 vs 真人偏好的**质量一致性**门禁（RFPerm-as-Judge）；
3. 表征批次几何对齐（embedding PCA/PC1-PC3）后再做预测漂移检验；
4. 多模态塔（视频/音频/文本）**哪一层在漂** → 决定 KV 刷新 / LoRA 更新预算；
5. 推荐/转化特征库（TencentGR 等）上 FSDS：RF-domain 看 $P(X)$ ，PO-risk 看 Y 差；
6. 门控 $\sqrt{PO}$ 重加权：安静时均匀，概念跳变时加热再退火。

目录

1 问题与边界	2
1.1 要解决的四类产品问题	2
1.2 刻意不做的宣称	3
1.3 开源与本地锚点	3
2 工具包总览：五层能力如何咬合	3

1 问题与边界	2
3 方法卡片（可贴进设计文档）	4
3.1 RFPerm	4
3.2 OnlineRFPerm	4
3.3 PO-learner (DRPerm / RRPerm / CFPerm)	4
3.4 门控 $\sqrt{PO}$ 重加权（本地已落地）	4
3.5 FSDS	5
3.6 多层 / 多场景 / 特征库图算法	5
4 可直接落地场景矩阵（LLM 重心）	5
4.1 A. 推理与预测监控	5
4.2 B. 幻觉与「看起来像回答」	6
4.3 C. 对齐与偏好一致性	6
4.4 D. 数据质量与表征对齐	6
4.5 E. 多模态与连续推理调度	6
4.6 F. 多层业务图（推荐 / 风控 / 交易）	7
5 已就绪数据与最小可行实验	7
6 场景 × 方法推荐表	8
7 落地 Playbook（可执行）	8
7.1 Playbook 1: LLM 输出质量流	8
7.2 Playbook 2: 对齐数据版本门禁	8
7.3 Playbook 3: 多模态连续推理	8
7.4 Playbook 4: 特征库漂移工单	9
8 与「不可能三角」对齐的工程结论	9
9 风险、回退与 MLOps 嵌入	9
10 优先级路线图（按「现在就能跑」）	9
11 结论	9

1 问题与边界

1.1 要解决的四类产品问题

1. 推理/预测是否在漂？部署模型 $\hat{f}$ 在连续到来的 (X_t, Y_t) 上，何时需要刷新？
2. 对齐与偏好是否一致？人工偏好、合成偏好、裁判模型、线上反馈是否同分布？
3. 幻觉与错误是否进入新制度？不是单条「对/错」，而是 $P(Y | X)$ 是否跳变。
4. 数据质量是否一致？特征库、embedding 批次、多模态塔、合成语料是否与参考批次对齐。

1.2 刻意不做的宣称

- 不做「特征 j 导致幻觉」的因果叙事。
- 不做无结构假设下 $P(X)$ 与 $P(Y \mid X)$ 的唯一全空间分解。
- 不把 DRE / PSI / KL 当成概念漂移的充分统计量。
- 不把 `po_risk0` 当成事实核查分数；它是相对上一探针的残差强度。

1.3 开源与本地锚点

组件	仓库 / 文档
RFPerm	https://github.com/ruanhq-StatsML/RFPerm
OnlineRFPerm	https://github.com/ruanhq-StatsML/OnlineRFPerm
PO-learner	https://github.com/ruanhq-StatsML/Causal_Objective_Permutation_Test
FSDS	https://github.com/ruanhq-StatsML/FSDS-FeatureSelection_for_Distrib
多层指标 PDF	同仓 FSDS_Sep14_MultiLayerFeatureSelection_Metrics.pdf
本地门控 PO	docs/po_risk/PO_risk_reweight_method.tex
幻觉原型	scripts/agod/rfperm_hallucination_proto.py (相关分支)

2 工具包总览：五层能力如何咬合

层	输入 / 输出	LLM 侧一句话
1. RFPerm	(X, Y) 参考 vs 新批；拒绝/接受预测退化	「这批回答/标签相对参考是否显著变差？」
2. OnlineRFPerm	流式误差 p -值 + SAF-FRON/ADDIS	「连续线上何时该刷模型/裁判？」
3. PO / R / CF	$T = 0/1$, PO-risk / R-risk, VIMP	「差在条件映射还是边缘画像？哪几维扛差？」
4. FSDS	协变量：RF-domain / MMD-LOCO；概念：PermuCATE / DRPerm	「特征库里哪一族在漂，该修特征还是重训头？」
5. 多层图	特征家族、模态塔、user-item 层级；HSIC/ASSOC 链	「跨场景/跨库联动漂，钻到子集再行动。」

推荐默认流水线（生产）。

1. 几何预检：embedding / 表征做批次 PCA (PC1-PC3) 与简单域分类 AUC——对齐可视化，不是最终决策。

2. **制度检验**: OnlineRFPerm (或门控 OOS 比) 决定是否 fire。
3. **轴诊断**: 安静则停; fire 后并行 RF-domain ($P(X)$) 与 PO/R ($P(Y | X)$ 代理)。
4. **特征/层定位**: FSDS top- k + 家族质量; 多层则 leave-one-group-out。
5. **行动**: quiet $\rightarrow$ 均匀; 概念异质 $\rightarrow \sqrt{\text{PO}}$ 重加权; 全局映射翻 $\rightarrow$ drop-old; 模态漂 $\rightarrow$ 刷新该塔 KV/更新预算。
6. **退火**: 下一跳 e_{prev} 变大, 比率自然回落, 回到均匀。

3 方法卡片 (可贴进设计文档)

3.1 RFPerm

做什么。用随机森林 (或任意有验证误差的模型) 比较参考上的验证/OOB 误差与新批上的预测误差; 置换生成零分布, 给出是否「预测性退化」的检验。密度感知, 对协变量与概念都敏感, 但不单独指认轴。

LLM 用法。把 prompt/表征当 X , 正确性/偏好/幻觉标签当 Y 。小样本 (约 30-40) 即可有功率; 适合每条合成样本「再测一次」的轻量门禁 (RFPerm-as-Judge)。

3.2 OnlineRFPerm

做什么。流式比较当前预测误差相对部署模型的极端性; Online FDR (SAFFRON/ADDIS, 含异步) 控假警。模态无关: 表格、图像、文本、视频、音频、轨迹均可, 前提是有合法预测模型。

LLM 用法。线上裁判分数、工具调用成功率、拒答率、幻觉率的**制度监测**; 可选把检测分数当 clever covariate 注入下一阶段轻量适应。

3.3 PO-learner (DRPerm / RRPerm / CFPerm)

做什么。旧批 $T = 0$, 新批 $T = 1$ 。双稳健伪结果 / R-learner 目标经 permute-then-refit; VIMP 解释为 **OOD 变量重要性**——元学习器是距离估计器, 不是因果效应估计器。R-risk 在投影理论下对 $P(X)$ 更不敏感, 用作概念轴代理; 仍非唯一分解证明。

LLM 用法。对齐偏移 (同一 prompt 分布, 偏好/正确性映射变了) vs 流量画像变了 (用户/任务 mix)。实例 $\text{po_risk}\theta_i = |Y_i - \mu_0(X_i)|$ (分类用 $1 - p$) 驱动排序与门控权重。

3.4 门控 $\sqrt{\text{PO}}$ 重加权 (本地已落地)

连续 OOS: $e_{\text{now}}/e_{\text{prev}} \geq \gamma$ (默认 1.5) 才 fire; fire 时 $T = 1$ 取 $w = \sqrt{\text{po_risk}\theta}$ (均值 1), 安静时 $w = 1$ 。平方损失下超额风险 $\Delta_t^2 = \mathbb{E}_t[(\mu_t^* - \mu_0)^2]$, 故门只在概念 OOD 相对噪声大时打开。DRE 只看 $p(x)$, 概念上贴近均匀、协变量上可能伤预测——与 synth/实盘一致。

两杠杆: **reweight** (软) 与 **drop-old** (硬, 一次性全局映射翻)。不要 always-on IPTW; 不要 PO-tail 过稀子集。

3.5 FSDS

协变量轴。 RF-domain OOB-VIMP、MMD/HSIC-LOCO、Boruta/ShadowVIMP——对 $P(X)$ 竞争强且常比 FSL-Net/DataFix 更省算力。

概念轴。 PermuCATE、DRPerm-LOCO、GRF VIMP、R-risk LOCO、Delta-Shapley、Knockoff/L1——元学习器在非线性概念上表现突出。

读法纪律。 先看 VIMP，再看 $\mathbb{E}[X | Q_1]$ vs $\mathbb{E}[X | Q_4]$ 等 post-hoc；质量 (mass) + 方向均值讲「后来的人长什么样」，不讲因果故事。TencentGR 时钟上已验证：cross/衰减/场内成交扛差，last-touch 归因家族不是漂移源。

3.6 多层 / 多场景 / 特征库图算法

动机。 电商与多模态系统特征天然分层 (user / item / session / merchant；或 audio / image / text)。全空间单特征唯一归因不可能；**分层子集定位**是正确动作。

ASSOC / HSIC 链。 对跨层指标算成对 HSIC，超阈为边，连通分量即指标链 (如 delivery-rating-orders-GMV)。只声明关联，不声明方向方向。

leave-one-group-out。 估计特征块/模态对漂移的贡献；再条件钻取 (先 region 再 category)，避免在全人口上混淆层级。

连续多模态推理调度。 FSDS 份额 π_m 指导：哪塔每窗重编码、哪路 KV 失效、哪塔拿 test-time 更新预算；静止 caption 编码一次复用。Attribution-Guided Online Distillation (AGOD) 把模态 gap 当 clever covariate 路由学生损失。

4 可直接落地场景矩阵 (LLM 重心)

下列场景均满足：方法已有实现、输入可从现有管线抽出、输出可接告警/门禁/重加权/调度。标记 * = 本仓库数据或原型已就绪。

4.1 A. 推理与预测监控

场景	首选方法	落地动作
A1 线上任务准确率/工具成功率制度跳变 *	OnlineRFPerm + 门控 OOS	fire → 告警；连续 FDR；可选 drop-old 裁判头
A2 延迟反馈 (点赞/客诉) 概念跳变	PO-risk 流 + RRPerm	映射变了再刷偏好头；画像变了只调采样
A3 多任务 router 是否跟错专家	FSDS on 任务 one-hot + 表征	哪任务块 VIMP 高 → 只重训该专家
A4 RAG 检索命中 vs 生成正确性	双 轴：RF-domain(检索特征) + PO(正确性)	检索漂 ≠ 生成漂；分别修索引/生成

4.2 B. 幻觉与「看起来像回答」

- **B1 制度级幻觉率监测 ***。合成概念切割：前静后噪。OnlineRFPerm/门控在切割跳 fire；实例 po_risk0 作候选排序（原型 AUROC $\sim 0.63-0.64$ ）。**不是事实核查。**
- **B2 幻觉标签器漂移。**同一生成分布，人标/自动标 Y 变了 $\rightarrow$ PO/R；生成 mix 变了 $\rightarrow$ RF-domain。
- **B3 拒答/安全策略 hop。**把安全动作当 Y ；监测策略头是否进入新工作点，避免把流量画像当「模型变坏」。

4.3 C. 对齐与偏好一致性

- **C1 人工偏好 vs 合成偏好。**RFPerm-as-Judge：小样本检验合成偏好是否预测性偏离真人批次。
- **C2 SFT/RLHF/DPO 数据版本门禁。**新旧偏好数据：FSDS 排出「哪类 prompt 特征」在扛差；门禁失败则拒合并。
- **C3 裁判模型校准。**裁判分数作 Y ；OnlineRFPerm 监视裁判相对黄金集是否漂；PO 高则抽检而非全量重标。
- **C4 指令跟随 vs 文风协变量。**文风/长度/语言 mix $\rightarrow$ RF-domain；正确性映射 $\rightarrow$ PO。避免用 PSI(长度) 解释正确率跌。

4.4 D. 数据质量与表征对齐

- **D1 Embedding 批次几何 ***。点云/文本/多模态 embedding：PC1-PC3 可视化 + 域分类 AUC；通过后再跑 RFPerm/FSDS。几何不对齐时先修管道。
- **D2 特征库健康 (TencentGR 类) ***。千维组合特征 $\rightarrow$ FSDS：RF 看队列画像，PO 看转化差；家族 mass 驱动修特征而非空谈「CTR 掉了」。
- **D3 合成语料多样性 vs 有害模式。**RFPerm 对质量标签；FSDS 定位有害模式特征（长度、模板 n-gram、嵌入簇）。
- **D4 训练-服务特征一致性。**同一特征名离线/在线两批当 $T = 0/1$ ；RF-domain 高 VIMP = 管道 bug 嫌疑清单。

4.5 E. 多模态与连续推理调度

- **E1 塔级归因 (MSR-VTT / ChronoBerg 类) ***。模态块 FSDS + PO；份额 π_v, π_a, π_t 决定重编码与更新掩码。
- **E2 连续 VLM 推理。**静止文本 encode-once；视觉/音频每窗刷新；KV 失效阈值用会话级监测，避免全局池化符号抵消。
- **E3 AGOD 蒸馏路由。** $\alpha_m = \text{softmax}(g_m/\tau)$ ， g_m 含域 AUC·VIMP + γ ·PO-risk；重叠差时回退 RF-domain。

4.6 F. 多层业务图（推荐 / 风控 / 交易）

- **F1 分层子集定位。**周批显著 → 先 user-region, 再 category; 输出 {subset, split rule, stability} 给业务 owner。
- **F2 ASSOC 指标链。**HSIC 边发现跨层联动（履约-评分-订单-GMV）; 告警「链」而非单点 KPI。
- **F3 反欺诈 mix vs 手法。**用例与开源 PDF 一致：欺诈者 mix = 协变量；手法 = 概念；两轴分开工单。

5 已就绪数据与最小可行实验

数据	形态	建议实验
data/public/*.npz	时间序列公开集	门控 $\sqrt{PO}$ vs DRE vs uniform（已有板）
data/tencent_subsets	推荐序列 + 特征库	FSDS 时间/业务时钟；家族 mass
ChronoBerg	/ 开源 FSDS 基准	概念/协变量特征选择复现
FMoW / WhyShift		
MSR-VTT 打包表	视频/音频/文本	模态归因 + AGOD 路由
幻觉合成流	原型脚本	fire@cut + po_risk0 排序
OpenML 表格	8 表 tabular	RF-domain vs FSL-Net 算力对比
(FSDS)		

最小命令（本地）。

```
# 幻觉制度原型（分支 cursor/rfperm-hallucination-92f8）
python3 scripts/agod/rfperm_hallucination_proto.py

# 门控 P0 方法说明：
# docs/agod/AGOD_online_rfperm.md
# docs/po_risk/P0_risk_reweight_method.tex

# Tencent 特征选择（时间时钟）
python3 scripts/tencent_gr/run_fsds_time.py
```

6 场景 × 方法推荐表

场景簇	RFPerm	Online	PO/R	FSDS/图
推理制度监测	•	•	•	
幻觉候选排序		•	•	
对齐/偏好门禁	•	•	•	•
表征几何对齐	•			•
特征库质量			•	•
多模态调度		•	•	•
多层业务钻取			•	•

•= 首选；•= 辅助。

7 落地 Playbook (可执行)

7.1 Playbook 1: LLM 输出质量流

1. 定义 $Y \in \{0, 1\}$: 正确 / 非幻觉 / 偏好胜出 (需标签或弱监督)。
2. X = 提示表征 (句向量) + 简单元特征 (长度、工具次数)。
3. 参考窗 B_{ref} 拟合浅 RF 探针 μ_0 ; 流式算 $e_{\text{now}}/e_{\text{prev}}$ 。
4. fire $\Rightarrow$ 告警 + 按 po_risk_0 抽检 Top- k ; 可选 $\sqrt{\text{PO}}$ 重拟合轻量头。
5. 同步 Online FDR, 防止夜间流量抖动刷屏。

7.2 Playbook 2: 对齐数据版本门禁

1. 旧偏好集 $T = 0$, 候选合并集 $T = 1$ 。
2. RF-domain: 若 AUC 很高且 top 特征是「来源 = 合成」 $\rightarrow$ 画像污染。
3. DRPerm/PermuCATE: 若概念轴显著 $\rightarrow$ 偏好映射已变, 需人工评审而非静默合并。
4. 门禁策略: 仅当两轴皆静 (或仅可解释协变量且业务签字) 才合并。

7.3 Playbook 3: 多模态连续推理

1. 每窗提 X_v, X_a, X_t ; 对参考窗跑块级 RF-domain + PO。
2. 得 π_m ; $\pi_t \approx 0$ 则 caption encode-once。
3. π_v 高则刷新视觉 KV / 提高视觉更新步数。
4. 文本 VIMP 异常升高当作**泄漏诊断**, 不作为加大语言塔预算的理由。

7.4 Playbook 4: 特征库漂移工单

1. 固定业务时钟 (时间分位 / 实验桶)。
2. 出 RF-mass 与 PO-mass 按家族; 附 $Q1 \rightarrow Q4$ 均值。
3. LOGO Δ 为负的家族不做「根因」故事。
4. 工单只修高 mass 且方向可解释的家族 (例如衰减点击、场内成交、cross)。

8 与「不可能三角」对齐的工程结论

1. 误差唯一分解不可能: 模型变差 vs 数据变差, 无结构假设不可分。
2. 轴唯一分解不可能: 除 KL 等特殊散度外, 不能从观测误差唯一拆 $P(X)$ vs $P(Y | X)$ 。
3. 单特征唯一分解不可能: 故用 VIMP + 子集定位, 不用「 x_j 贡献 23% 漂移」作 KPI。
4. 可做的: 联合敏感检验 (RFPerm); 轴代理 (R/PO vs domain); 子集/层定位; 门控适应。

9 风险、回退与 MLOps 嵌入

- **重叠差**: 倾向分极端时 meta-learner 不稳——回退 RF-domain / 拒火 / 扩参考窗。
- **空室分母**: 分类 $e_{\text{prev}} \approx 0$ 会制造假火——设 e_{floor} 。
- **Always-on IPTW**: 安静钟上输给均匀——默认均匀, 门控加热。
- **并行**: 置换检验可并行, 文献称可降 60%-70% 墙钟。
- **嵌入点**: 特征质量看板、合并门禁、在线告警、多模态调度器、合成数据验收。

10 优先级路线图 (按「现在就能跑」)

1. **P0 (本周)**: 公开时钟门控 PO 板保持; 幻觉原型接入真实裁判标签; TencentGR FSDS 工单模板固化。
2. **P1**: 对齐数据版本门禁 (人工 vs 合成偏好) 接 CI。
3. **P1**: MSR-VTT/多模态 $\pi_m \rightarrow$ 推理调度配置。
4. **P2**: ASSOC 指标链接到业务 KPI 图谱。
5. **P2**: Online FDR 接到生产告警总线。

11 结论

RFPerm / OnlineRFPerm / PO-learner / FSDS / 多层图算法已经构成一条从**检验** $\rightarrow$ **定位** $\rightarrow$ **门控适应** $\rightarrow$ **调度**的闭环。放在大模型场景里, 最值钱的不是又一个「幻觉分数」, 而是:

在数据与标签已就绪的前提下，用有统计门控的制度检测，配上可解释的特征/模态定位，再把算力与重加权只花在真正 fire 的跳变上，并在下一跳退火回去。

FSDS 尤其适合作为**特征库与多塔一致性**的默认诊断层；PO-learner 适合**对齐映射与概念跳变**；OnlineRFPerm 适合**线上制度**；多层 ASSOC 适合**跨场景钻取**。严格遵守「检测 $\neq$ 因果、定位 $\neq$ 唯一分解」，这套工具就可以直接进生产，而不是停在论文图。

英文版见同目录 LLM_FSDS_Landing_Report_EN.tex。

编译

```
cd docs/reports
xelatex LLM_FSDS_Landing_Report_CN.tex
pdflatex LLM_FSDS_Landing_Report_EN.tex
```