

多模态归因：做特征就是在拆成交

asof / 指针没有方法论含量。含量在：同一笔转化，用几种触点去对，你会看见这门生意到底是怎么成交的。特征不是先想 150 维再找故事；是先问「这单从哪来、买完人还在不在」，对得上再留列。

事件 (user, item, act, ts)，0=曝光 1=点击 2=转化。转化一行一张中间表。
计算 (asof $\equiv$ 指针、跟满窗) 见 POST_CALC.md。下面只讲业务：对上是什么、对不上说明什么、该留哪列。

1. 为什么要「多模态」

只用同品 last-click，你默认了漏斗是：

看见这件 → 点这件 → 买这件

电商信息流经常不是这样。几种触点是几种生意，不是几种算法：

模态	asof	你在问的生意
同品 last-click	cnv $\leftarrow$ clk, by=(user,item), backward	这件点完多久下单 (SKU 决策)
任意 last-click	cnv $\leftarrow$ clk, by=user, backward	刚逛完别的，转手买了这件 (场/推荐)
同品 first-click	每 (user,item) 只留最早一次点，再 backward	从第一次注意到下单，考虑期
同品 last-曝光	cnv $\leftarrow$ exp, by=(user,item), backward	看过没点就买 (漏点、曝光即买)
当场	不是 asof: 本场、本条之前点了几次	逛热了才买，还是一场开头就买
买后任意点	cnv $\rightarrow$ clk, by=user, forward	买完人还在不在平台
买后同品点	cnv $\rightarrow$ clk, by=(user,item), forward	这件买完还看不看 (复访/后悔/晒单)

多模态 = 这几路同时对。路与路的占比，就是成交构成。某一路几乎对不上，不是特征废了，是这条生意假设被数据否了——这正是做特征要得到的。

同一对 (last_clk, cnv) 从点击侧看是 merge_asof(clk, cnv, forward)：「这次点击之后下一次转化」。粒换成点击，才是「点了会不会买」。路径分析停在转化粒。

2. 这批 prefix 的成交构成 (6000 user / 12866 cnv)

先对模态，再决定堆哪些列。prefix_frac=0.75。

模态	单数	占比	读法
B 只点过别的，再买这件	6619	51.5%	有点击，但点的不是成交 SKU
D 序列里看不见任何点击	6220	48.3%	这条 seq 上没有 clk 可归因
A 同品点过再买	14	0.11%	经典 SKU 漏斗，几乎不存在
C 同品只曝光、没点就买	13	0.10%	「漏点/曝光即买」也几乎对不上

同品 last-曝光能对上的也只有 0.20%。
任意 last-click 能对上的 51.6%，dt_any 中位 4.1 天 (p90 $\approx$ 21 天) ——不是当场点完就买。

当场: `sess_clk_before=0` 占 98.4%, `sess_pos` 中位 = 1。转化经常是一场的开头或孤立事件, 不是「逛热了再下单」。

所以: 如果你只做同品 last-click, 12866 单里 14 单有数, 其余全是空路径。空填 0 分钟会假装「秒下」, 那是假故事。

这批信息流的成交, 主模态是 B 跨品点击 + D 序列外/未记录触点, 不是 SKU 漏斗。

3. 各模态: 对上了讲什么, 留什么列

A. 同品 last-click (这批 n=14)

业务: 这件点完多久买。dt_item 中位 139 分钟; within_5m 约 21% (样本极小)。first-click 和 last-click 相同——看不见「考虑很久、最后一击成交」。

该留: dt_item、item_within_5m/1h、wo_prior_clk。

justify: 这是 SKU 归因的标准问法, 必须算; 算完看占比。占比≈0 时, 这些列近似常数, 别指望它们预测任何东西 (这批 wo_prior_clk 系数就是 0)。列还是要有: 下次换场景 (商详、搜推) 占比会变, 模态表就是监控。

B. 任意 last-click (这批 51.5%)

业务: 人在平台上动过手, 但成交 SKU 不是刚才点的那件。Last-click 若记到 SKU, 会把功劳记错商品; 记到用户「还在逛」, 才对。

该留: dt_any、是否有任意点击。

justify: 跨品是推荐/信息流的主路径——曝光队列把另一件卖出去了。dt_any 中位 4 天, 说明连「任意 last-click」也不是 5 分钟冲动, 是隔了好几天的回访成交。短桶 within_5m 对这批任意路径几乎无效; 长间隔才是这模态的形状。

C. 同品只曝光没点 (这批 n=13)

业务: 看过这件、没点、买了。漏点、货架冲动、或点击没记上。

该留: dt_exp_item、wo_prior_exp_item。

justify: 和 A 一起, 才能区分「点了才买」vs「看见就买」。这批两路都空, 说明成交 SKU 经常根本没在这条曝光序列里出现——不是漏点, 是覆盖/归因链路不在 seq 里。这是数据业务结论, 不是窗口开错了。

D. 序列里没有点击 (48.3%)

业务: 在你用来做特征的这段 prefix 上, 这单没有 clk 可挂。可能是站外/直播/订单回写、可能是点击未入 seq、可能是更早的点被 prefix 切掉。

不要把 dt 填 0。单独一档「空路径」。

justify: D 的买后 1d 任意点击率 6.8%, B 是 15.7%。看不见触点的成交, 买完也不怎么点——更像成交被写进来的人, 不像还在信息流里逛的人。混在一起建模, 会把两种生意平均掉。

4. 当场 sess_clk_before

定义: 本场 (相邻间隔 ≤30min)、本条转化之前的点击数。不是用户级 sess_n / bounce。

这批 98.4% = 0, 场深中位 1。生意含义: 转化事件常常自己开一场, 前面没有「先点几下再买」。

那 1.6% sess_clk_before>0 的单, 买后 1d 点击率 29% vs 11%。热场里买完还会点——这是续逛, 不是购买带动。

该留：sess_clk_before、sess_pos。

justify: 短窗买后点击的主混杂。评估必须拆窗：跟 y_5m / next_clk_same_sess 绑在一起，当场就做对了；控住买前 7d 量还能预测 y_1d，漏的是用户热度，不是场。这批 1d 上当场几乎没增量，和 98% 为 0 是同一件事。

5. 买后：任意 vs 同品

```
next    = merge_asof(cnv, clk, by=user, forward, exact=False)
next_i  = merge_asof(cnv, clk, by=(user,item), forward, exact=False)
```

只用跟满窗的单：没点到且 follow<W 不当 0。

这批（跟满 1d）：任意点击率 11.3%，同品 0.10%；1d after≈before；lift 中位 0；有下一次点时，仍在当场 30min 的只有 2.3%；dt_next 中位约 6 天。

justify:

- 同品买后≈0 和同品买前≈0 是一件事：这条序列上，成交 SKU 就不是互动对象。还去做「买完带动同品点击」没有事件。
- 任意买后 11%、7d 到 41%，是「人还在平台」，不是这单余热。所以 1d Y 的主信号是买前 7d 量和滞后买后率（爱点的人继续点），不是路径短桶。
- lift 任意窗会被连单污染；同品 lift 干净，但这批同品基数先死了。

滞后 lag_post_clk_1d_rate：这个人以前买完爱不爱点，给下一单。必须 shift(1)。这批它是 1d 预测头名——用户倾向，不是这一单的路径。

6. 评估：验证的是生意假设，不是 AUC

先出模态表（§2），再消融。按用户切。Y 只用跟满窗。X 不含买后量。

你以为的生意	特征上该看到	这批实际
SKU 点完就买	A 占比高，within_5m 高	A=0.11%，假设不成立
曝光即买这件	C 占比高	C=0.10%，同品曝光也对不上
逛热了再买	sess_clk_before>0 多	98% 为 0
买完还看这件	y_post_same_1d 有基数	千分之一，先别建模
买完带动平台点击	n_after > n_before	after≈before，lift 中位 0
跨品逛完再买	B 占比高，dt_any 有形状	B=51.5%，dt_any 中位 4 天
空路径是另一种人	D 的买后点击更低	6.8% vs B 的 15.7%

消融怎么读：

- volume 已经 0.68（1d 任意）：基线就是「爱点的人还在点」
- +同品 path 几乎不动：模态 A 不存在，列没有方差
- +dt_any / 有没有任意点击：在测模态 B
- +sess 短窗涨、长窗不涨：当场续逛
- +lag 长窗涨：用户稳定倾向

F-score 对着 future_cnv 会把成交次数推上去，看不见模态。不要用。

7. 自己落地：先模态表，再留列

1. 转化中间表，四路 backward：同品 clk、任意 clk、同品 first clk、同品 last exp。空单独记，禁止填 0。
2. 当场：sess_clk_before、sess_pos。
3. Forward：任意 / 同品 next clk，跟满窗才留 y 和 n_after。
4. 先打一张模态占比 + $E[\text{买后}Y|\text{模态}]$ 。占比 ≈ 0 的路，列保留作监控，不进主模型。
5. 主模型用对得上的路：这批就是任意路径、买前量、滞后、空路径档。
6. 用户表只并历史倾向（未删失 mean/median），交叉最后乘。

换场景（商详、搜推、广告）时重出 S2 那张表。模态变了，该留的列才变。这就是多模态归因的用处：不是更炫的模型，是每次做特征把成交构成核对一遍。

TencentGR prefix 6000 user / 12866 cnv · 多模态是成交构成，不是新模型