

路径、指针与 merge_asof

转化粒特征：怎么刻画、怎么评估。自己落地时按这个做即可。

事件 (user, item, act, ts), act ∈ {0=曝光, 1=点击, 2=转化}。先按 (ts, act) 排：同秒点击在转化前。t_end = 该用户序列最后一条 ts。

本文不是因果、不是 CATE。asof 只是「以某条事件为锚，找另一类事件的最近一次」。

1. 原语

```
merge_asof(left=锚, right=候选, by=组, left_on=ts, right_on=ts,
            direction=backward|forward, allow_exact_matches=exact)
```

参数	含义
by=user	同一个人
by=(user, item)	同一个人同一商品
backward	锚时刻之前 (含/不合同秒由 exact 定) 最近一条候选
forward	锚时刻之后最近一条候选
exact=True	同秒算匹配
exact=False	同秒不算; forward 时「下一次」必须严格晚于锚

pandas 3: 时间键必须**全局单调**，不能只按 (user, item) 排。by 仍按组匹配。

指针扫一遍和 asof 同构：

- backward: 正向扫，候选更新指针，锚出现时读指针。
- forward: 锚推进 pending，候选出现时把还没闭上的锚闭上。

窗内计数用累计：

```
C(t) = #{ 候选 | ts ≤ t }
n_(t-W, t] = C(t) - C(t-W)
n_(t, t+W] = C(t+W) - C(t)
```

C(t) 本身也是 merge_asof(锚, 候选.cumcount, backward, exact=True)。

2. 已经成立的一块：最近一次点击 → 这一次转化

这是路径。锚 = 转化，候选 = 点击，direction=backward。

```
last_item = merge_asof(cnv, clk, by=(user, item), backward, exact=True)
last_any  = merge_asof(cnv, clk, by=user,          backward, exact=True)
first_item: 每个 (user, item) 只留最早一次点击，再 backward asof
```

落地字段 (转化一行)：

字段	计算	在问什么
dt_item	(cnv_ts - last_item.ts) / 60 , 空则空	这件商品点完多久下单
dt_any	(cnv_ts - last_any.ts) / 60	全局上次点完多久下单
wo_prior_clk	last_item 空	这件从未点过就买
item_within_B	dt_item ≤ B 且非空	5m / 30m / 1h / 1d 桶

指针（正向扫）：

```
last_any, last_item = None, {}
if CLK: last_any = ts; last_item[item] = ts
if CNV: dt_any = ts - last_any; dt_item = ts - last_item[item]
```

同一对 (last_clk, cnv) 从点击侧看就是「这次点击之后的下一次转化」：

```
next_cnv = merge_asof(clk, cnv, by=(user, item), forward, exact=False)
```

和 last_item 是同一批配对，只是粒从转化换成点击。路径分析停在转化粒；若做「点了会不会买」才用点击粒。

3. 对偶：这一次转化 → 下一次点击

锚 = 转化，候选 = 点击，direction=forward，exact=False。

```
next      = merge_asof(cnv, clk, by=user,          forward, exact=False)
next_i    = merge_asof(cnv, clk, by=(user, item), forward, exact=False)
dt        = next.ts - cnv_ts          # 没有 next → 空
follow    = t_end - cnv_ts
```

只用跟满窗的单。窗 $W \in \{5m, 1h, 1d, 7d\}$ ：

```
y_post_clk_W = 1{ dt ≤ W }
               ; follow ≥ W 且没点到 → 0
               ; follow < W 且没点到 → 丢掉 (NaN, 不当 0)
y_post_same_W = 同上, 用 next_i
```

窗内已点到即使 follow < W 也算 1（事件已经发生）。没点到且没跟满，不知道，不能当负例。

trans_cnv_to_exp 是邻接 Markov（下一条事件），不是窗内点击，不要替代这一块。

4. 还有哪些 asof 值得做

同一原语，换锚 / 候选 / by / 方向。建议都做成转化粒或对应锚粒中间表，不要先堆用户一行。

锚	候选	方向	by	字段直觉
cnv	clk	backward	item / user	路径 (\$2, 必做)
cnv	clk	backward	item, 只留 first	从第一次点到下单
cnv	clk	forward	user / item	买后下一次点 (\$3, 必做)
cnv	cnv	forward	user / item	下一次买 / 复购同品
cnv	exp	forward	user / item	买后又看没看
cnv	exp	backward	item	最后一次曝光到下单 (无点击路径)
clk	cnv	forward	item	点完会不会买 (点击粒)
clk	clk	forward	user	点完还会不会点 (较少单独做)

场内版：匹配后再加 `dt ≤ 30min` (或先按 session id 切开再 asof)。用来区分当场续点 vs 隔场回访。

同长窗 before/after 计数 (任意 / 同品) 是 asof 的累计形式, 不是新原语。

用户一行只对未删失转化做 `mean / median`, 再 join。交叉最后乘。

5. 路径怎么刻画、怎么评估

路径 = 转化时刻已经知道的 backward asof, 不准含任何买后信息。

刻画 (转化粒, 先不要模型) :

- `P(wo_prior_clk)`、`dt_item / dt_any` 的分位数、各 `within_B` 占比
- 空值单独一档, 不要填 0 (0 分钟 = 刚点完就买)
- 和当场一起切: `within_5m × sess_clk_before > 0` = 热场短路径; `wo_prior_clk × sess_clk_before = 0` = 冷场直达

评估 (预测买后点击时) :

- 样本: `follow ≥ W` 的转化
- `Y = y_post_clk_W` 或 `y_post_same_W` (更稀、更干净)
- 对照: 只拿买前点击量 `n_clk_before_W`; 再加路径; 看 AUC/AP 增量
- 短窗 Y (5m/1h) 路径和当场才应该有用; 1d/7d 任意点击多半是「人还在」, 路径增量会很小
- 不要用 F-score 对着 `future_cnv` 选这些列

6. 当场: `sess_clk_before`

不是 asof。一场 = 相邻事件间隔 ≤ 30min; 超过就关场。

```
sess_pos          = 本场第几条 (含本条转化)
sess_clk_before   = 本场、本条之前的点击数
```

指针:

```
若 ts - prev_ts > 30min: sess_pos = 0; sess_clk = 0
sess_pos += 1
CLK 时 sess_clk += 1
CNV 时读出 sess_pos, sess_clk_before = sess_clk
```

刻画什么：下单这一刻场热不热。`sess_clk_before=0`：这场还没点过就买（曝光即买 / 新场第一条附近）。`≥1`：买之前这场已经动过手。它是「买后立刻又点」的主混杂——场没关，下一击几乎是续逛。

怎么评估：

1. 分布：转化上 `sess_clk_before` 的直方图；对比随机事件上的同一量（转化是否更爱落在热场）。
2. 和 Y 的关系要按窗拆：
3. 与 `y_post_clk_5m / next_clk_same_sess` 强相关 → 当场续点，不是购买带动。
4. 控住 `n_clk_before_1d` 之后仍预测 `y_post_clk_1d` → 泄漏的是用户热度，不是场。
5. 消融：`volume` → `+sess` → 看短窗 Y 和长窗 Y 分别涨多少。短窗涨、长窗不涨，当场就做对了。
6. 不要和用户级 `sess_n / sess_bounce_rate` 混。那两个是整段历史的场统计；`sess_clk_before` 是这一单所在场。

7. 滞后

```
lag_post_clk_W_rate = mean( 此前各单的 y_post_clk_W | 非 NaN )
n_prior_cnv          = 此前转化条数
```

必须 `shift(1)`：本单的 Y 不能进本单的 X。此前单若当时没跟满窗，那一单不进均值。

刻画：用户「买完还点」的倾向，给下一单用。

评估：`volume` 之上再加 `lag`，`1d/7d Y` 通常这是最大增量；短窗 Y 不该主要靠 `lag`（那是当场的事）。

8. 评估协议（自己做特征时按这个收）

粒：转化一行。用户任务（如 `future_cnv`）只并历史倾向，不要拿本单买后量去预测用户未来转化。

删失：预测窗 W 的模型，只用 `follow ≥ W` 的单；或窗内已观察到正例的单。负例必须跟满。

X：只有 `cnv_ts` 已知的量——路径、买前窗计数、当场、价格、滞后。

不准进：`n_after`、`lift`、`dt_next`、`y_post_*`。

切分：按 `user_id` 切，不要随机切转化（`lag` 和用户热度会漏）。

先刻画后模型：

1. 未删失集合上的 `P(y_post_clk_W)`、`P(y_post_same_W)`
2. `n_after` vs `n_before`（任意 / 同品）；`P(dt ≤ 30min | 有 next)`
3. `E[X | Y=1]` vs `E[X | Y=0]`：路径、当场、`lag` 分列
4. 再消融 AUC/AP：`volume` → `+path` → `+sess` → `+lag`

读增量：

消融涨在哪	说明
只有 volume	爱点的人继续点
+path 在短窗	决策时长 / 漏点在管当场余热
+sess 在短窗、长窗不动	当场续逛，不是买完回访
+lag 在长窗	用户稳定倾向
同品 Y 正例极少	「买完还看这件」事件本身稀，先报基数再建模

不要：全样本 F-score、删失当 0、用邻接转移代替窗、把用户级 bounce 当成当场。

9. 建议落地顺序

1. 转化中间表：\$2 路径 asof (item / any / first)
2. 同一张表：\$3 forward asof + follow + y_W (先 1h/1d)
3. 累计 n_before_W / n_after_W (after 只在跟满时留)
4. 扫场：sess_pos、sess_clk_before
5. 按转化时间 lag
6. 按 \$8 出一张刻画表 + 一组消融，再决定哪些进用户表

中间表 polish 后再 user_id merge。交叉最后做。

转化粒 · merge_asof ≡ 指针 · 只用跟满窗的单 · 路径 / 当场 / 滞后分开评估